TRƯỜNG ĐẠI HỌC BÁCH KHOA - ĐẠI HỌC ĐÀ NẴNG

KHOA ĐIỆN TỬ - VIỄN THÔNG

PBL4: TRÍ TUỆ NHÂN TẠO

ĐỀ TÀI:

NGHIÊN CỨU VÀ ỨNG DỤNG HỌC SÂU ĐA PHƯƠNG THỨC TRONG PHÂN TÍCH CẢM XÚC CON NGƯỜI

GVHD: TS. Trần Thị Minh Hạnh

SVTH : Lê Văn Minh Trí – 22KTMT1

Hà Tiến Đạt – 22KTMT2

Đà Nẵng, 6/2026

MỤC LỤC

1. Giới thiệu 3
2. Các nghiên cứu liên quan 4
2.1. Tổng quan về nhận dạng cảm xúc qua khuôn mặt 4
2.2. Tổng quan về phân tích cảm xúc từ giọng nói qua chuyển đổi văn bản 5
3. Phương pháp 6
3.1 Kiến trúc tổng thể của hệ thống 6
3.2. Phương thức thị giác (ResNet18) 7
3.3. Phương thức giọng nói (PhoWhisper) 10
3.4. Phương thức ngữ nghĩa (XLM-RoBERTa) 12
3.5. Cơ chế kết hợp đa phương thức 14
4. Kết quả thực nghiệm và đánh giá 15
4.1. Đánh giá luồng thị giác 15
4.2. Đánh giá luồng văn bản 16
4.3. Đánh giá luồng giọng nói 18
4.4. Đánh giá hệ thống đa phương thức 19
5. Kết luận và hướng phát triển 21
5.1. Kết luận 21
5.2. Hạn chế 22
5.3. Hướng phát triển tương lai 22

1. Giới thiệu

Trong cuộc sống, sức khỏe được hình thành từ hai yếu tố: thể chất và tinh thần. Do đó, việc hỗ trợ chăm sóc sức khỏe tinh thần nên được nâng cao tầm quan trọng như chăm sóc về thể chất. Đặc biệt là trong thời đại số, nơi mà áp lực công việc hoặc học tập có thể tác động trực tiếp đến người lao động, học sinh, sinh viên. Nhận dạng được tầm quan trọng của khía cạnh tinh thần trong chăm sóc sức khỏe, việc xây dựng một hệ thống nhận dạng cảm xúc đa phương thức sẽ một phần nào hỗ trợ các y bác sĩ trong việc chẩn đoán, đồng thời cung cấp công cụ theo dõi tâm lý người dùng theo thời gian thực.

Mặc dù nhận dạng cảm xúc là một lĩnh vực nghiên cứu rộng lớn, phần lớn các công trình vẫn tập trung vào một kênh thông tin duy nhất. Về khía cạnh nhận dạng cảm xúc qua khuôn mặt [1], đây là kênh phổ biến và phát triển mạnh nhất, nhưng vẫn gặp giới hạn khi khuôn mặt bị che khuất hoặc người dùng cố tình che giấu cảm xúc. Kênh giọng nói cũng thu hút nhiều nhà nghiên cứu [2], với các mô hình sử dụng mạng nơ ron hồi quy kết hợp cơ chế chú ý để trích xuất cảm xúc từ tín hiệu âm thanh thô; tuy nhiên, nhiễu môi trường và sự đa dạng giọng vùng miền vẫn là trở ngại lớn trong việc tổng quát hóa. Kênh văn bản cũng được ứng dụng rộng rãi, từ phân tích bình luận phim [3] đến phân tích cảm xúc trên mạng xã hội [4], với ưu điểm phản ánh ngữ nghĩa sâu sắc nhưng phụ thuộc nhiều vào khả năng diễn đạt của từng cá nhân. Bên cạnh đó, các kênh thông tin khác như cử chỉ cơ thể [5] hay tín hiệu sinh học EEG [6] tuy mang tính chân thực cao nhưng đòi hỏi thiết bị chuyên dụng và khó triển khai trong điều kiện thực tiễn phổ thông.

Việc phụ thuộc vào một mô hình đơn lẻ dễ dẫn đến đánh giá chủ quan, thiếu toàn diện — đặc biệt trong bối cảnh sức khỏe tâm thần, nơi người dùng có thể biểu hiện cảm xúc không nhất quán giữa các kênh. Chính vì vậy, báo cáo này trình bày một hệ thống giám sát sức khỏe tâm thần đa phương thức, tích hợp ba nguồn thông tin độc lập, nhận dạng cảm xúc qua: khuôn mặt, văn bản và giọng nói.

Về kiến trúc mô hình, hệ thống sử dụng ResNet18 [10] — mạng thặng dư sâu đã được chứng minh hiệu quả trên tập dữ liệu RAF-DB [14], [15] — cho nhánh thị giác; mô hình XLM-RoBERTa [19] — kiến trúc Transformer đa ngôn ngữ — cho nhánh văn bản với khả năng xử lý đồng thời tiếng Anh và tiếng Việt; và PhoWhisper [26] — mô hình nhận dạng giọng nói tự động tinh chỉnh cho tiếng Việt từ Whisper [25] trên tập VietSuperSpeech [27] — cho nhánh giọng nói. Kết quả từ ba mô hình được tổng hợp thông qua cơ chế confidence-weighted fusion [29], trong đó trọng số của từng mô hình được điều chỉnh động theo độ tin cậy dự đoán, thay vì cố định như các phương pháp late fusion truyền thống.

Mục tiêu của đề tài là xây dựng một ứng dụng web cho phép người dùng ghi nhật ký hàng ngày kết hợp với nhận diện khuôn mặt qua camera, từ đó theo dõi xu hướng cảm xúc theo thời gian, phát hiện trạng thái hidden mood — khi văn bản tích cực nhưng khuôn mặt tiêu cực — và đưa ra cảnh báo sớm khi có dấu hiệu bất thường về tâm lý. Hệ thống hướng

đến vai trò cầu nối giữa người dùng gặp vấn đề tâm lý với các dịch vụ hỗ trợ sức khỏe tâm thần chuyên nghiệp.

2. Các nghiên cứu liên quan

2.1. Tổng quan về nhận dạng cảm xúc qua khuôn mặt

Trong bài toán nhận dạng cảm xúc qua khuôn mặt (Facial Expression Recognition - FER), các mạng nơ-ron tích chập (Convolutional Neural Network - CNN) đã chứng minh hiệu năng vượt trội trong việc giải quyết các thách thức của thị giác máy tính. Thông qua kỹ thuật Học chuyển giao (Transfer Learning), các kiến trúc CNN kinh điển thường được tái sử dụng làm bộ trích xuất đặc trưng (Feature Extractor) hay còn gọi là mạng xương sống (Backbone). Lịch sử phát triển của mạng CNN ghi nhận nhiều kiến trúc nổi bật: mạng VGG [7] với thiết kế xếp chồng các lớp tích chập nhỏ gọn đạt hiệu quả cao nhưng tiêu tốn lượng lớn tham số; mạng Inception (GoogLeNet) [8] tối ưu hóa tài nguyên bằng cách trích xuất đặc trưng ở nhiều độ phân giải khác nhau cùng lúc; hay mạng DenseNet [9] giải quyết vấn đề suy biến đạo hàm (vanishing gradient) bằng cách kết nối trực tiếp tất cả các lớp với nhau để tái sử dụng tối đa đặc trưng.

Kế thừa những tiến bộ đó, hệ thống trong báo cáo sử dụng kiến trúc ResNet-18 [10] làm backbone. Kiến trúc này được lựa chọn không chỉ vì khả năng tận dụng trọng số đã được huấn luyện trước (pre-trained weights) từ tập dữ liệu ImageNet quy mô lớn [11], mà cốt lõi nằm ở thiết kế Khối thặng dư (Residual Block). Khối thặng dư cho phép mạng học các ánh xạ đồng nhất (identity mappings), giúp mô hình hội tụ nhanh, giải quyết triệt để lỗi suy biến đạo hàm khi mạng học sâu hơn. Hơn nữa, với kích thước mô hình tinh gọn, ResNet-18 đáp ứng hoàn hảo yêu cầu về tốc độ suy luận (Inference time) và tốc độ khung hình (FPS) cho một hệ thống phân tích cảm xúc theo thời gian thực.

Bên cạnh yếu tố thuật toán, chất lượng của bộ dữ liệu đóng vai trò quyết định đến độ chính xác của mô hình FER. Lịch sử nghiên cứu ghi nhận sự chuyển dịch từ các tập dữ liệu được thu thập trong môi trường phòng thí nghiệm được kiểm soát nghiêm ngặt (In-the-lab) như JAFFE [12] – bao gồm 213 ảnh tĩnh của 10 phụ nữ Nhật Bản; sang các tập dữ liệu thu thập trong môi trường tự nhiên (In-the-wild) nhằm tăng tính tổng quát hóa. Các bộ dữ liệu tự nhiên tiêu biểu bao gồm FER-2013 [13] với 35.887 ảnh và ExpW [14] chứa 91.793 ảnh bối cảnh thực.

Trong khuôn khổ đồ án này, tập dữ liệu RAF-DB (Real-world Affective Faces Database) [15] được lựa chọn để huấn luyện mô hình. RAF-DB cung cấp 15.339 ảnh khuôn mặt tự nhiên, được chia thành 12.271 ảnh huấn luyện và 3.068 ảnh kiểm tra. Điểm ưu việt vượt trội của RAF-DB so với các bộ dữ liệu khác là tính đa dạng sinh trắc học và độ tin cậy của nhãn: mỗi bức ảnh được gán nhãn độc lập bởi khoảng 40 người (crowdsourcing) để lọc bỏ các đánh giá chủ quan. Dữ liệu được phân loại thành 7 biểu cảm cơ bản: Ngạc nhiên (Surprise), Sợ hãi (Fear), Ghê tởm (Disgust), Vui vẻ (Happiness), Buồn bã (Sadness), Giận

dữ (Anger) và Bình thường (Neutral). Tuy nhiên, đặc tính phân phối tự nhiên của RAF-DB cũng đặt ra một thách thức kỹ thuật lớn về sự mất cân bằng giữa các lớp (Class Imbalance) – một vấn đề sẽ được nhóm phân tích và xử lý thực nghiệm ở các chương tiếp theo.

2.2. Tổng quan về phân tích cảm xúc từ giọng nói qua chuyển đổi văn bản

Phân tích cảm xúc từ văn bản (text-based emotion recognition) là một trong những hướng nghiên cứu phát triển mạnh mẽ nhất trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt kể từ khi kiến trúc Transformer được giới thiệu. Imran [16] thực hiện so sánh toàn diện các mô hình Transformer tiền huấn luyện bao gồm BERT, RoBERTa và XLM-RoBERTa trên bài toán phân loại cảm xúc trong văn bản kỹ thuật phần mềm, kết quả cho thấy các mô hình dựa trên Transformer vượt trội đáng kể so với các phương pháp truyền thống như SVM hay LSTM. Rezapour [17] mở rộng phạm vi so sánh sang nhiều miền dữ liệu khác nhau, khẳng định rằng việc tinh chỉnh (fine-tuning) mô hình Transformer theo miền cụ thể giúp cải thiện đáng kể khả năng tổng quát hóa trên dữ liệu thực tế so với mô hình gốc chưa tinh chỉnh. Huang [18] tổng hợp các xu hướng học sâu trong phân tích cảm xúc văn bản, nhấn mạnh rằng các mô hình đa ngôn ngữ như XLM-RoBERTa [19] — được huấn luyện trên hơn 100 ngôn ngữ với 2,5TB dữ liệu — mang lại lợi thế lớn trong các bài toán song ngữ hoặc đa ngôn ngữ, cho phép xử lý đồng thời nhiều ngôn ngữ mà không cần bước dịch thuật trung gian.

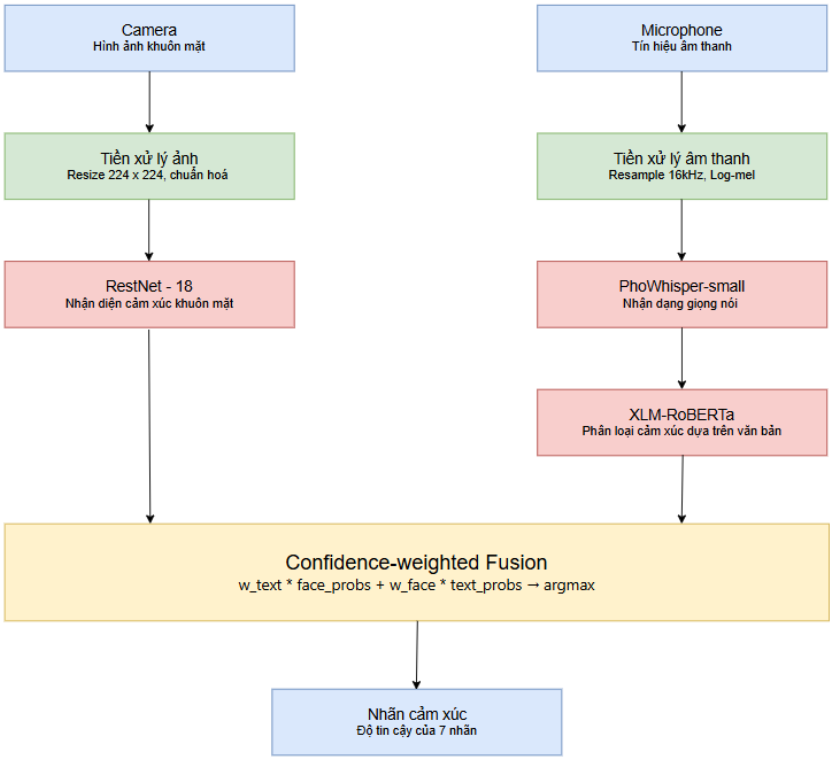
Bên cạnh kênh văn bản, nhận dạng cảm xúc qua giọng nói cũng là một hướng nghiên cứu được quan tâm rộng rãi. Mirsamadi et al. [2] đề xuất sử dụng mạng nơ ron hồi quy (RNN) kết hợp cơ chế chú ý cục bộ (local attention) để trích xuất đặc trưng cảm xúc từ tín hiệu âm thanh thô, đạt kết quả tốt trên các tập dữ liệu chuẩn nhưng gặp hạn chế khi triển khai trong môi trường nhiều nhiễu. Wang et al. [29] đề xuất kiến trúc Multimodal Transformer kết hợp đặc trưng âm thanh và văn bản để nhận dạng cảm xúc từ giọng nói, cho thấy việc khai thác đồng thời thông tin ngữ nghĩa và âm học cải thiện đáng kể độ chính xác so với từng kênh riêng lẻ.

Về nhánh chuyển giọng nói sang văn bản (ASR), Radford et al. [25] giới thiệu mô hình Whisper — được huấn luyện trên 680.000 giờ âm thanh đa ngôn ngữ với cơ chế giám sát yếu (weak supervision) — đặt nền tảng cho các hệ thống ASR hiện đại có khả năng nhận dạng mạnh mẽ trong điều kiện nhiễu và đa dạng ngôn ngữ. Tuy nhiên, hiệu suất của Whisper trên tiếng Việt còn hạn chế do đặc thù hệ thống thanh điệu và sự đa dạng giọng vùng miền. Le et al. [26] phát triển PhoWhisper — tinh chỉnh Whisper trên 844 giờ tiếng Việt từ nhiều nguồn và nhiều giọng miền khác nhau — đạt WER thấp hơn đáng kể so với Whisper gốc trên các benchmark tiếng Việt chuẩn bao gồm VIVOS, VLSP 2020 và CMV-Vi. Do et al. [27] giới thiệu VietSuperSpeech — tập dữ liệu hội thoại tiếng Việt quy mô lớn thu thập từ các ngữ cảnh thực tế như chatbot, hỗ trợ khách hàng và tổng đài — cung cấp nền tảng dữ liệu phù hợp để tinh chỉnh mô hình ASR cho các ứng dụng giao tiếp tự nhiên.

Nhìn chung, các nghiên cứu trên cho thấy xu hướng tích hợp ASR và phân tích cảm xúc văn bản thành một pipeline end-to-end đang ngày càng được quan tâm, nhờ khả năng phản ánh cảm xúc tự nhiên hơn so với văn bản được soạn thảo có chủ đích, đồng thời mở rộng đối tượng người dùng không muốn hoặc không thể nhập liệu bằng bàn phím.

3. Phương pháp

3.1 Kiến trúc tổng thể của hệ thống



Hình 1. Kiến trúc tổng thể của hệ thống nhận dạng cảm xúc đa phương thức

Hình 1 mô tả kiến trúc tổng thể của hệ thống nhận diện cảm xúc đa phương thức, bao gồm bốn tầng xử lý chính được tổ chức theo hai nhánh song song: nhánh thị giác xử lý hình ảnh khuôn mặt và nhánh ngôn ngữ xử lý giọng nói, trước khi hội tụ tại tầng tổng hợp để ra quyết định cuối cùng.

Ở tầng đầu vào, hệ thống tiếp nhận đồng thời hai luồng dữ liệu từ hai thiết bị thu thập khác nhau. Luồng thứ nhất là hình ảnh khuôn mặt từ camera, được biểu diễn dưới dạng mảng numpy ở không gian màu BGR. Luồng thứ hai là tín hiệu âm thanh từ microphone, được thu dưới dạng cặp (sampling rate, numpy array). Ở tầng tiền xử lý, mỗi luồng được xử lý độc lập theo đặc thù của từng phương thức. Đối với nhánh thị giác, hình ảnh đầu vào được đưa qua bộ phát hiện khuôn mặt Haar Cascade để xác định và cắt vùng khuôn mặt, sau đó điều chỉnh kích thước về 224×224 pixel và chuẩn hóa theo phân phối ImageNet. Đối với nhánh giọng nói, tín hiệu âm thanh được chuyển từ stereo sang mono, chuẩn hóa biên

độ về khoảng [-1, 1] và resample về tần số 16kHz để phù hợp với đầu vào của mô hình nhận dạng giọng nói.

Ở tầng phân tích đặc trưng, hệ thống sử dụng ba mô hình học sâu chuyên biệt. Trên nhánh thị giác, mô hình ResNet-18 nhận ảnh khuôn mặt đã tiền xử lý và trích xuất đặc trưng để dự đoán phân bố xác suất trên 7 nhãn cảm xúc cơ bản. Trên nhánh giọng nói, mô hình PhoWhisper-small thực hiện nhận dạng tiếng nói tự động, chuyển đổi tín hiệu âm thanh thành văn bản tiếng Việt. Văn bản này tiếp tục được đưa vào mô hình XLM-RoBERTa để phân tích ngữ nghĩa và phân loại cảm xúc dựa trên nội dung ngôn ngữ, cho ra phân bố xác suất trên cùng 7 nhãn cảm xúc.

Ở tầng tổng hợp và quyết định, phân bố xác suất từ hai nhánh được kết hợp thông qua cơ chế Confidence-weighted Fusion. Thay vì sử dụng trọng số cố định, trọng số của mỗi phương thức được tính động tại mỗi lần dự đoán dựa trên độ tin cậy đầu ra của chính mô hình đó — tức là giá trị xác suất cao nhất trong phân bố đầu ra. Mô hình nào cho kết quả chắc chắn hơn sẽ được tin tưởng nhiều hơn trong quyết định cuối cùng. Xác suất tổng hợp cho từng nhãn cảm xúc được tính bằng tổng có trọng số của hai phân bố, sau đó nhãn có giá trị tổng hợp cao nhất được chọn làm kết quả cuối cùng kèm theo độ tin cậy tương ứng.

Cơ chế này mang lại khả năng thích nghi linh hoạt theo chất lượng đầu vào thực tế. Chẳng hạn, khi ánh sáng kém hoặc khuôn mặt không rõ khiến ResNet-18 cho phân bố xác suất dàn trải, trọng số của nhánh thị giác tự động giảm và hệ thống nghiêng về kết quả từ nhánh ngữ nghĩa, và ngược lại. Trong trường hợp không có đầu vào hình ảnh, toàn bộ trọng số được dồn về phương thức ngữ nghĩa, đảm bảo pipeline vẫn hoạt động bình thường chỉ với văn bản.

Bên cạnh đó, tại mỗi lần phân tích, hệ thống còn kiểm tra sự mâu thuẫn giữa hai phương thức — cụ thể là trường hợp văn bản thể hiện cảm xúc tích cực trong khi khuôn mặt cho thấy cảm xúc tiêu cực. Hiện tượng này được gọi là hidden mood, phản ánh trạng thái cảm xúc bị che giấu mà người dùng không thể hiện rõ qua ngôn ngữ. Khi phát hiện, hệ thống đưa ra cảnh báo riêng để người dùng lưu ý, độc lập với nhãn cảm xúc cuối cùng được tổng hợp.

3.2. Phương thức thị giác (ResNet18)

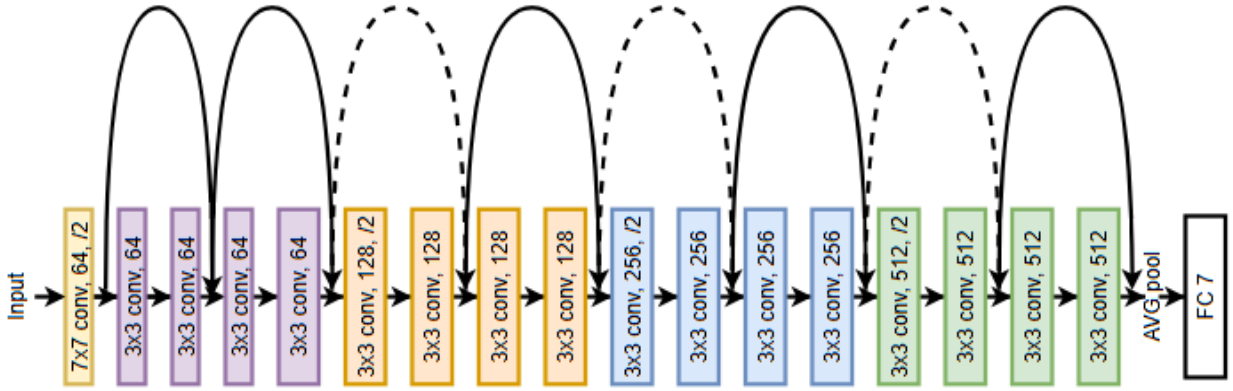
3.2.1. Kiến trúc mô hình ResNet18

Để thực hiện nhiệm vụ trích xuất đặc trưng và phân loại cảm xúc khuôn mặt, hệ thống sử dụng kiến trúc mạng thặng dư ResNet-18 làm xương sống. Là mô hình xử lý ảnh được huấn luyện từ trước (pre-trained) dựa trên tập ImageNet [11], mô hình này đã sở hữu các tham số phù hợp cho việc nhận dạng khuôn mặt. Kiến trúc ResNet-18 được mô tả trong hình 1 với 17 lớp tích chập (Convolutional layers) và 1 lớp kết nối hoàn chỉnh (Fully Connected) với 7 lớp đầu ra là các nhãn cảm xúc cơ bản. Ngoài ra, cơ chế Dropout 50% được thực hiện khi khởi tạo mô hình, giúp mô hình hạn chế việc học vẹt. Về tổng quan, kiến

trúc này có thể chia thành 3 khối gồm: Khối xử lý sơ bộ đầu vào; Khối thặng dư; và Khối phân loại và đầu ra.

Khối xử lý sơ bộ đầu vào nhận hình ảnh khuôn mặt với kích thước 224x224 pixel được chuẩn hóa và đưa vào lớp tích chập 7x7 đầu tiên, với số kênh đầu ra là 64 với bước nhảy (stride) là 2. Lớp này có nhiệm vụ hạ độ phân giải không gian của ảnh ngay từ bước đầu tiên để giảm tải chi phí tính toán cho các tầng sau, đồng thời trích xuất các đặc trưng cơ bản như cạnh, góc và mảng màu.

Sau đó, dữ liệu được xử lý qua 4 khối thặng dư (Residual Layers), được ký hiệu bằng các màu sắc khác nhau trong Hình 2. Mỗi tầng thặng dư này chứa 2 khối nhỏ cơ bản (Basic Blocks), tương ứng với 4 lớp tích chập 3x3 trên mỗi tầng. Đi sâu vào từng tầng, tầng 1 (màu tím) có nhiệm vụ duy trì độ phân giải và trích xuất đặc trưng ở không gian hẹp với 64 kênh dữ liệu. Cơ chế kết nối tắt (Shortcut connection) được thể hiện bằng đường mũi tên liền nét, thực hiện ánh xạ đồng nhất (Identity mapping) do kích thước ma trận giữa đầu vào và đầu ra của khối hoàn toàn trùng khớp. Các tầng thặng dư còn lại (có màu cam, xanh dương, xanh lá) lần lượt mở rộng chiều sâu bộ lọc lên thành 128, 256, 512 kênh đặc trưng. Tại khối đầu tiên của các tầng này, phép hạ không gian mẫu thành một nửa giá trị ban đầu (Downsampling) được thực hiện với lớp tích chập 3x3, bước nhảy (stride) là 2. Do có sự lệch pha về số chiều, kết nối tắt ở các tầng này được biểu diễn bằng mũi tên nét đứt, đại diện cho việc sử dụng phép tích chập 1x1 để đồng bộ hóa số lượng kênh và kích thước ma trận trước khi thực hiện phép cộng phần tử (element wise addition).

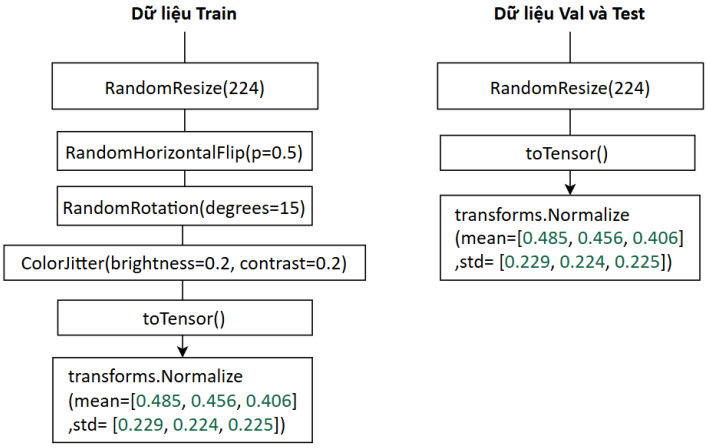


Hình 2. Kiến trúc ResNet-18

Khối phân loại và đầu ra bắt đầu với việc lấy trung bình toàn cục được áp dụng để nén toàn bộ thông tin không gian phẳng thành một vector đặc trưng duy nhất gồm 512 chiều. Cuối cùng, lớp kết nối hoàn chỉnh thực hiện ánh xạ tuyến tính từ không gian đặc trưng 512 chiều sang 7 điểm số chưa được chuẩn hóa, đại diện cho 7 nhãn cảm xúc cơ bản của tập dữ liệu.

3.2.2. Thiết lập luồng dữ liệu đầu vào

Thiết lập luồng dữ liệu đầu vào bắt đầu với Tiền xử lý và Chuẩn hóa dữ liệu đầu vào được diễn tả trong hình 3, ảnh gốc được thay đổi kích thước lên chuẩn 224x224 pixel. Sau đó thực hiện tăng cường dữ liệu bằng việc lật ảnh ngẫu nhiên theo chiều ngang với xác suất 50% (RandomHorizontalFlip), đồng thời xoay ngẫu nhiên 1 góc -15 đến 15 độ (RandomRotation). Điều này cực kỳ quan trọng cho ứng dụng chạy webcam thực tế, giúp mô hình bắt được biểu cảm ngay cả khi người dùng nghiêng đầu, lệch cổ trước camera. Tiếp theo là thay đổi ngẫu nhiên độ sáng và độ tương phản trong phạm vi dải 20% nhằm tăng độ bền bỉ cho mô hình, cho mô hình làm quen với ánh sáng thay đổi. Các pixel ảnh đồng thời được chuyển sang dạng Tensor và chuẩn hóa theo phân phối chuẩn của tập dữ liệu ImageNet với giá trị kỳ vọng $\mu = [0.485, 0.456, 0.406]$ và độ lệch chuẩn $\sigma = [0.229,0.224,0.225]$ được diễn tả trong phương trình 1. Việc đồng bộ phân phối dải này giúp dữ liệu tận dụng tối đa hiệu năng của bộ trọng số đã được huấn luyện từ trước, tăng tốc độ hội tụ và tránh hiện tượng bùng nổ hoặc triệt tiêu đạo hàm.



Hình 3. Thiết lập tiền xử lý và tăng cường dữ liệu

$$X_{norm} = \frac{X - \mu}{\sigma} \quad (1)$$

Phân chia tập dữ liệu và cân bằng Weighted Sampler được thực hiện với mục tiêu làm sao đánh giá mô hình một cách khách quan nhất và chống học vẹt. Dữ liệu tập Train gốc được chia ngẫu nhiên thành 85% cho tập Train và 15% cho tập Valid, sử dụng cơ chế thiết lập seed cố định bằng manual_seed(42) nhằm đảm bảo tính tái tạo của thực nghiệm. Tập Valid và Test không được áp dụng các phép tăng cường để đảm bảo kết quả đánh giá khách quan nhất. Tiếp theo, kỹ thuật WeightedRandomSampler được sử dụng trực tiếp trong bộ nạp DataLoader để giải quyết bài toán mất cân bằng dữ liệu trên Batch cấp cho GPU. Tần suất xuất hiện của các nhãn lớp trong tập huấn luyện mới được thống kê thông qua hàm đếm ma trận (torch.bincount). Trọng số của mỗi lớp cảm xúc được tính toán nghịch đảo theo số lượng mẫu của chính lớp đó, trọng số càng cao thì số lượng ảnh của các lớp thiểu số trong

một batch được tăng theo, ngăn chặn hiện tượng thiên vị hoàn toàn trên tập dữ liệu bị mất cân bằng.

3.2.3. Tiến trình huấn luyện

Chiến lược huấn luyện bắt đầu với lựa chọn hàm mất mát là Cross Entropy Loss, hàm này sẽ đo lường sai số giữa phân phối xác suất dự đoán từ Softmax của mô hình và nhãn thực tế dưới dạng One-hot được biểu diễn trong phương trình 2. N là kích thước Batch, C là số nhãn, y_{ic} là nhãn thực tế của mẫu i thuộc về lớp c, p_{ic} là xác suất mô hình dự đoán mẫu i thuộc về lớp c. Về thuật toán tối ưu hóa, nhóm sử dụng AdamW (Adam with Decoupled Weight Decay).

$$L_{CE} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} y_{ic}\log(p_{ic}) \quad (2)$$

Để giải quyết bài toán mô hình bị mắc kẹt tại các điểm tối ưu cục bộ (Local Minimum) hoặc dao động quá mạnh quanh điểm cực tiểu toàn cục ở các Epoch cuối, nhóm triển khai bộ lập lịch ReduceLROnPlateau. Khác với các bộ điều khiển giảm tốc độ học cố định theo chu kỳ (StepLR), ReduceLROnPlateau vận hành theo cơ chế giám sát phản hồi. Bộ lịch này theo dõi trực tiếp chỉ số Độ chính xác trên tập Validation (epoch_valid_acc) với cấu hình mode='max'. Nếu chỉ số này không có sự cải thiện tăng tiến sau liên tiếp 3 Epoch (patience=3), hệ thống hiểu rằng mô hình đã bão hòa tại mức năng lượng đó và độ học sẽ được tự động nhân với hệ số giảm factor=0.5 (giảm đi một nửa). Giải pháp này giúp mô hình thu nhỏ bước nhảy, tiến hành dò tìm mịn hơn ở các thung lũng hàm mất mát, tối ưu hóa sâu hơn năng lực hội tụ. Một loạt các siêu tham số sử dụng trong tiến trình huấn luyện được liệt kê trong Bảng 1.

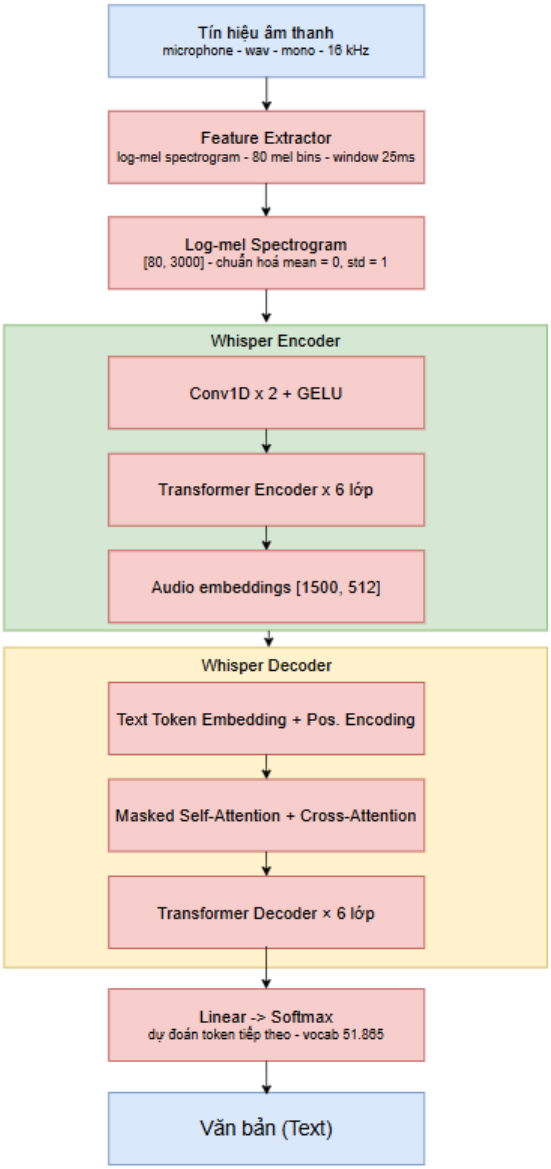
Bảng 1. Siêu tham số trong tiến trình huấn luyện ResNet

Siêu tham số	**Thiết lập**	**Siêu tham số**	**Thiết lập**
Batch_size	64	Weight Decay	1e-4
Epochs	20	Scheduler	ReduceLROnPlateau
Hàm mất mát	Cross-Entropy Loss	Learning rate	1e-4
Bộ tối ưu hóa (Optimizer)	AdamW		

3.3. Phương thức giọng nói (PhoWhisper)

PhoWhisper-small là mô hình nhận dạng giọng nói tự động (ASR) chuyên biệt cho tiếng Việt, được phát triển bởi VinAI Research dựa trên kiến trúc Whisper của OpenAI [25], [26]. Với 244 triệu tham số, PhoWhisper-small được lựa chọn vì đạt sự cân bằng tốt giữa hiệu suất nhận dạng và tốc độ suy luận trên CPU, phù hợp với yêu cầu triển khai thực tế của hệ thống. Trong đề tài này, mô hình được fine-tune thêm trên tập VietSuperSpeech [27] — tập

dữ liệu hội thoại tiếng Việt quy mô lớn thu thập từ các ngữ cảnh giao tiếp tự nhiên — nhằm cải thiện độ chính xác nhận dạng trong điều kiện nói tự nhiên, không có kịch bản.



Hình 4. Kiến trúc mô hình PhoWhisper-small

Kiến trúc PhoWhisper (Hình 4) theo mô hình encoder-decoder, trong đó hai nhánh đảm nhiệm hai vai trò riêng biệt: encoder trích xuất đặc trưng âm thanh, decoder sinh văn bản theo cơ chế tự hồi quy.

Ở nhánh encoder, tín hiệu âm thanh đầu vào được resample về 16 kHz, sau đó chuyển thành log-mel spectrogram với 80 mel bin, cửa sổ phân tích 25 ms và bước dịch 10 ms. Đặc trưng thô này đi qua hai lớp tích chập 1D (Conv1D) với hàm kích hoạt GELU để trích xuất các đặc trưng cục bộ theo trục thời gian. Đầu ra được bổ sung positional encoding dạng sinusoidal rồi đưa qua 6 lớp Transformer encoder, mỗi lớp gồm multi-head self-attention và

feed-forward network, tạo ra chuỗi audio embeddings có kích thước $[1500 \times 512]$, trong đó 1500 là số khung thời gian và 512 là số chiều đặc trưng.

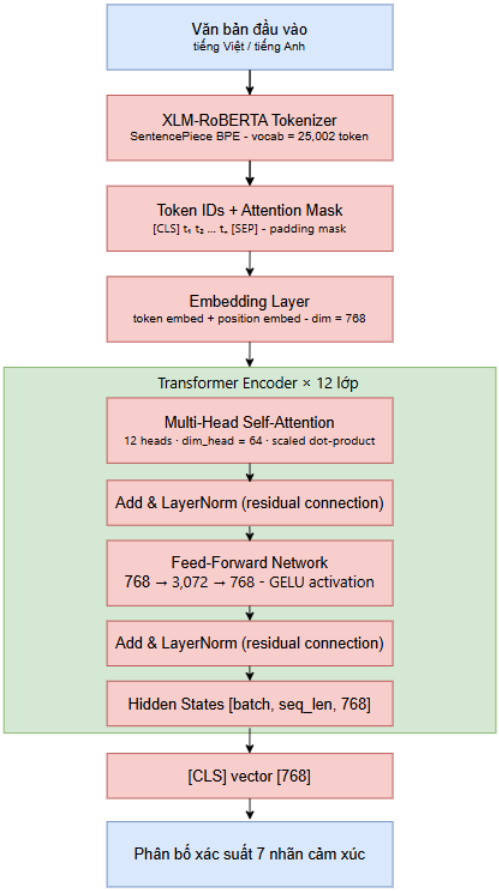
Ở nhánh decoder, mô hình hoạt động theo cơ chế tự hồi quy: token văn bản được dự đoán tuần tự từ trái sang phải, mỗi bước nhận toàn bộ chuỗi token đã sinh trước đó làm đầu vào. Cụ thể, embedding của các token trước được cộng với positional encoding, đưa qua cơ chế masked self-attention để mô hình hóa phụ thuộc giữa các token đầu ra mà không nhìn thấy tương lai, tiếp theo là cross-attention để tham chiếu trực tiếp audio embeddings từ encoder, và feed-forward network. Sau 6 lớp Transformer decoder, vector đầu ra chiều 512 được chiếu qua lớp tuyến tính và softmax trên từ vựng 51.865 token để xác định xác suất token tiếp theo.

Quá trình fine-tune sử dụng 8.000 mẫu huấn luyện và 500 mẫu kiểm định trích từ VietSuperSpeech. Mô hình được tối ưu bằng AdamW với learning rate 10^{-5}, linear warmup trong 100 bước đầu, batch size hiệu dụng 32 (batch 8 × gradient accumulation 4 bước). Checkpoint tốt nhất được chọn dựa trên Word Error Rate (WER) thấp nhất trên tập kiểm định.

Văn bản tiếng Việt sau khi được sinh ra hoàn toàn được chuyển sang XLM-RoBERTa để phân tích cảm xúc, đảm bảo tính nhất quán trong toàn bộ pipeline của hệ thống.

3.4. Phương thức ngữ nghĩa (XLM-RoBERTa)

Mô hình XLM-RoBERTa-base là một kiến trúc Transformer đa ngôn ngữ được huấn luyện trên 100 ngôn ngữ với 2,5TB dữ liệu văn bản, được fine-tune cho bài toán phân loại 7 nhãn cảm xúc trong hệ thống này. Ưu điểm nổi bật của mô hình là khả năng xử lý đồng thời tiếng Anh và tiếng Việt trong cùng một mô hình thống nhất mà không cần bước dịch thuật trung gian, nhờ vào bộ tokenizer SentencePiece BPE với từ vựng 250.002 token được học từ dữ liệu đa ngôn ngữ [19].



Hình 5. Kiến trúc mô hình XLM-RoBERTa-base

Quy trình xử lý trong Hình 5 bắt đầu từ văn bản đầu vào được mã hóa thành chuỗi token ID kèm theo attention mask, giới hạn tối đa 128 token. Chuỗi token sau đó đi qua lớp embedding để chuyển thành vector liên tục với số chiều 768, kết hợp giữa token embedding và position embedding. Tiếp theo, biểu diễn này được đưa qua 12 lớp Transformer encoder, mỗi lớp bao gồm cơ chế multi-head self-attention với 12 đầu chú ý và kích thước mỗi đầu là 64, tiếp nối bởi lớp feed-forward network với chiều trung gian 3.072, cùng với kết nối tắt và layer normalization sau mỗi thành phần. Vector đầu ra tại vị trí token [CLS] — đại diện cho ngữ nghĩa toàn câu với chiều 768 — được đưa qua lớp phân loại tuyến tính để chiếu xuống không gian 7 chiều, sau đó áp dụng hàm softmax để thu được phân bố xác suất trên 7 nhãn cảm xúc: sadness, joy, love, anger, fear, surprise và neutral.

Quá trình fine-tune được thực hiện theo chiến lược hai bước nhằm tối ưu hóa hiệu suất mô hình trên cả ngữ cảnh đa ngôn ngữ lẫn đặc thù tiếng Việt, một chiến lược được ghi nhận là hiệu quả trong các nghiên cứu phân loại cảm xúc đa miền [17]. Ở bước đầu tiên — *general-domain fine-tuning* — toàn bộ tham số mô hình được huấn luyện trên 70.000 mẫu từ tập dữ liệu cảm xúc đa ngôn ngữ của HuggingFace với learning rate 2e-5, giúp mô hình hình thành năng lực phân loại cảm xúc tổng quát trên nhiều ngôn ngữ và phong cách văn

bản khác nhau. Ở bước thứ hai — *domain-specific fine-tuning* — mô hình tiếp tục được tinh chỉnh với learning rate thấp hơn (1e-5) trên 13.800 mẫu tiếng Việt đời thường được tạo bán tự động qua Groq API, nhằm thích nghi với đặc thù ngôn ngữ hội thoại hàng ngày bao gồm các câu ngắn, mơ hồ, thiếu chủ ngữ và mang tính biểu cảm cao. Việc sử dụng learning rate thấp ở bước hai có tác dụng bảo toàn kiến thức đã học từ bước trước trong khi vẫn cho phép thích nghi với miền mới, tránh hiện tượng catastrophic forgetting.

3.5. Cơ chế kết hợp đa phương thức

Sau khi hai nhánh mô hình — ResNet-18 cho phương thức thị giác và XLM-RoBERTa cho phương thức ngữ nghĩa — tạo ra phân bố xác suất độc lập, hệ thống thực hiện bước tổng hợp đa phương thức để đưa ra nhãn cảm xúc cuối cùng. Quá trình này gồm hai giai đoạn chính: đồng nhất không gian nhãn và hợp nhất quyết định có trọng số động.

Do hai mô hình được huấn luyện trên các tập dữ liệu khác nhau, chúng có sự khác biệt về không gian nhãn. ResNet-18 được huấn luyện trên tập FER với 7 nhãn cảm xúc khuôn mặt gồm: *surprise, fear, disgust, happiness, sadness, anger, neutral*, trong khi XLM-RoBERTa phân loại văn bản theo 7 nhãn: *sadness, joy, love, anger, fear, surprise, neutral*. Để đưa hai không gian nhãn về một cơ sở chung, hệ thống thực hiện ánh xạ một-một: *happiness* được chuyển thành *joy* và *disgust* được chuyển thành *anger* do tính tương đồng về biểu hiện cảm xúc. Sau bước ánh xạ, cả hai nhánh đều biểu diễn kết quả trên cùng một tập 7 nhãn thống nhất: {*sadness, joy, love, anger, fear, surprise, neutral*}.

Sau khi đồng nhất không gian nhãn, xác suất từ hai nhánh được tổng hợp theo cơ chế hợp nhất có trọng số động theo độ tin cậy. Trọng số của mỗi phương thức không cố định mà được tính tại từng lần dự đoán dựa trên giá trị xác suất cực đại trong phân bố đầu ra của chính mô hình đó — gọi là độ tin cậy ngữ nghĩa (cho XLM-RoBERTa) và độ tin cậy thị giác (cho ResNet-18):

$$w_{\text{ngữ nghĩa}} = \frac{c_{\text{ngữ nghĩa}}}{c_{\text{ngữ nghĩa}} + c_{\text{thị giác}}}, w_{\text{thị giác}} = \frac{c_{\text{thị giác}}}{c_{\text{ngữ nghĩa}} + c_{\text{thị giác}}} \quad (3)$$

Xác suất tổng hợp cho mỗi nhãn cảm xúc eđược tính theo công thức:

$$P_{\text{tổng hợp}}(e) = w_{\text{ngữ nghĩa}} \cdot P_{\text{ngữ nghĩa}}(e) + w_{\text{thị giác}} \cdot P_{\text{thị giác}}(e) \quad (4)$$

Nhãn cảm xúc cuối cùng được xác định bằng:

$$\hat{e} = \arg\max_{e} \; P_{\text{tổng hợp}}(e) \quad (5)$$

Cơ chế này cho phép hệ thống tự động điều chỉnh mức độ tin tưởng vào từng phương thức tùy theo chất lượng đầu vào thực tế. Chẳng hạn, khi khuôn mặt không rõ hoặc ánh sáng kém khiến ResNet-18 cho độ tin cậy thị giác thấp, trọng số tương ứng tự động giảm và hệ thống nghiêng về kết quả từ phương thức ngữ nghĩa, và ngược lại. Trong trường hợp không có đầu vào hình ảnh, hệ thống đặt trọng số ngữ nghĩa bằng 1,0 và trọng số thị giác bằng 0,0, đảm bảo pipeline vẫn hoạt động bình thường chỉ với một phương thức duy nhất.

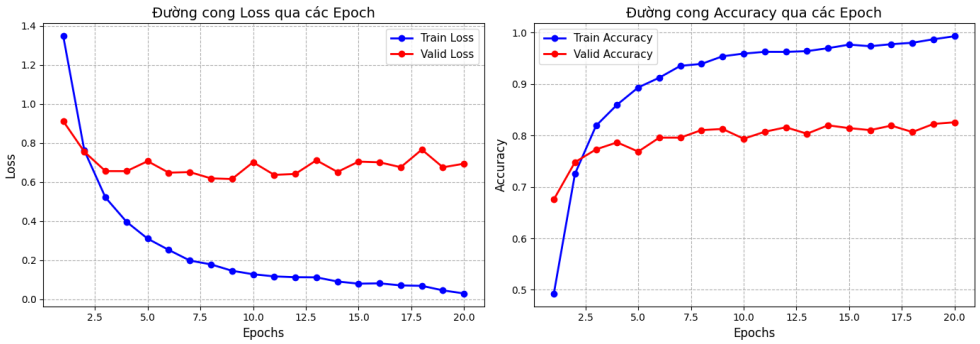
Ngoài dự đoán tại từng thời điểm, hệ thống còn thực hiện theo dõi cảm xúc liên tục trong suốt phiên tương tác. Nhãn cảm xúc được ghi nhận định kỳ và tổng hợp bằng cách tính tần suất xuất hiện của từng nhãn trên tổng số lần quan sát, từ đó xác định cảm xúc chủ đạo trong phiên làm việc. Phương pháp này giúp hệ thống phản ánh trạng thái cảm xúc tổng thể của người dùng một cách ổn định hơn so với việc chỉ dựa vào một thời điểm quan sát đơn lẻ.

4. Kết quả thực nghiệm và đánh giá

4.1. Đánh giá luồng thị giác

4.1.1. Đánh giá quá trình huấn luyện (Learning Curves)

Đường cong huấn luyện qua 20 epoch (Hình 6) cho thấy mô hình xuất hiện hiện tượng Overfitting (Quá khớp) rõ rệt từ nửa sau quá trình huấn luyện. Cụ thể, độ mất mát (Loss) trên tập Huấn luyện (Train) liên tục giảm mạnh và tiến sát về mốc 0, trong khi độ mất mát trên tập Kiểm thử (Valid) bắt đầu dao động mạnh quanh ngưỡng 0.7. Tương tự, độ chính xác (Accuracy) tập Train tiệm cận mức 100% nhưng tập Valid bị bão hòa tại 83%. Trạng thái tối ưu nhất của mô hình đạt được tại tập Valid với độ chính xác cao nhất là 0.8256.



Hình 6. Đồ thị đường cong huấn luyện

4.1.2. Hiệu năng tổng thể trên tập Test

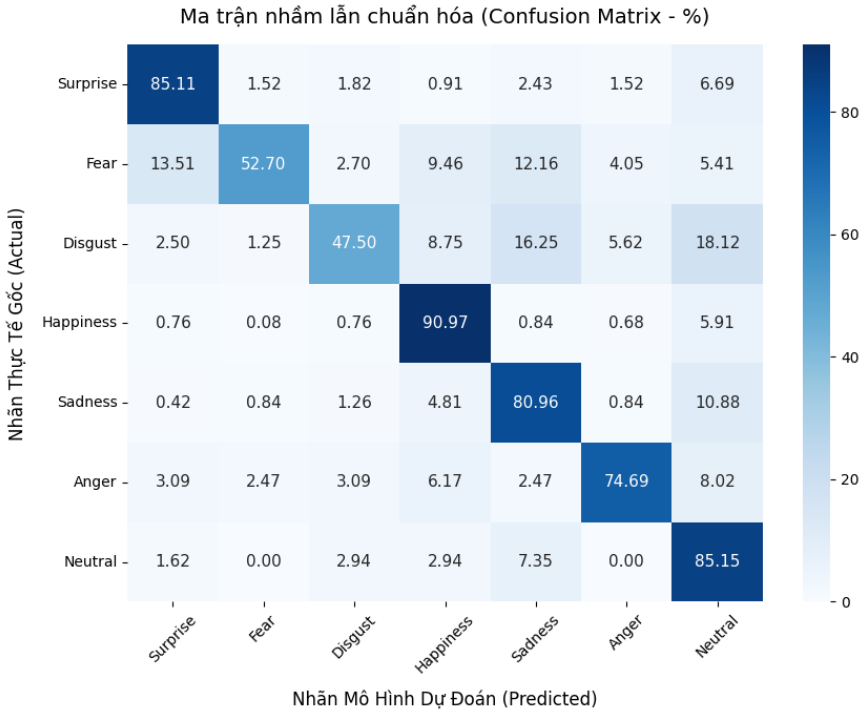
Bảng 2 cung cấp các thông số dùng để đánh giá hiệu năng mô hình trên tập Test, về tổng quan mô hình đạt được độ chính xác tổng thể là 83.44% (cao hơn 1% so với tập Valid), cho thấy khả năng tổng quát hóa rất tốt của mô hình. Các chỉ số như Precision , Recall lần lượt là 78.15% và 73.87%, chênh lệch chỉ 5% cho thấy mô hình đạt được trạng thái cân bằng lý tưởng. Qua đó đạt được con số khá tốt với F1-Score là 75.63%.

Bảng 2. Tiêu chí đánh giá mô hình trên tập Test

Tiêu chí (Macro)	Accuracy	Precision	Recall	F1-Score
Kết quả	0.8344	0.7815	0.7387	0.7563

4.1.3. Phân tích không gian biểu cảm qua Ma trận nhầm lẫn

Nhóm các nhãn đa số được thể hiện trong hình 7 có lượng lớn mẫu đạt tỷ lệ chính xác rất cao. Dẫn đầu là Happiness 90.97%, theo sau lần lượt là Neutral 85.15%, Surprise 85.11%, và Sadness 80.96%. Nhóm các nhãn thiểu số bao gồm: Anger đạt chỉ lệ chính xác khá tốt với 74.69%, tiếp theo là Fear 52.7%, và Disgust 47.5%. Lớp Disgust bị nhầm nhiều nhất khi bị nhầm sang Neutral 18.12% và Sadness 16.25% số mẫu dữ liệu.

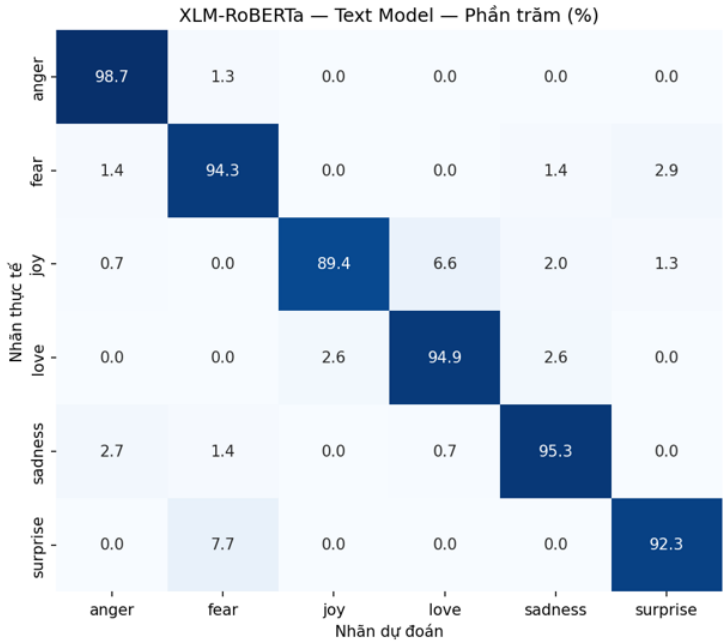


Hình 7. Ma trận nhầm lẫn trên tập Test

4.2. Đánh giá luồng văn bản

Luồng văn bản được đánh giá trên tập kiểm thử độc lập từ bộ dữ liệu dair-ai/emotion với 500 mẫu, bao gồm 6 nhãn cảm xúc: sadness, joy, love, anger, fear và surprise. Tập kiểm thử này hoàn toàn tách biệt khỏi dữ liệu huấn luyện, đảm bảo tính khách quan trong đánh giá.

Kết quả tổng thể cho thấy mô hình XLM-RoBERTa đạt độ chính xác 93,80%, với Precision macro 89,18%, Recall macro 94,15% và F1-score macro 91,30%. Hình 4 trình bày ma trận nhầm lẫn của mô hình trên tập kiểm thử, thể hiện số lượng dự đoán đúng và sai theo từng cặp nhãn cảm xúc.

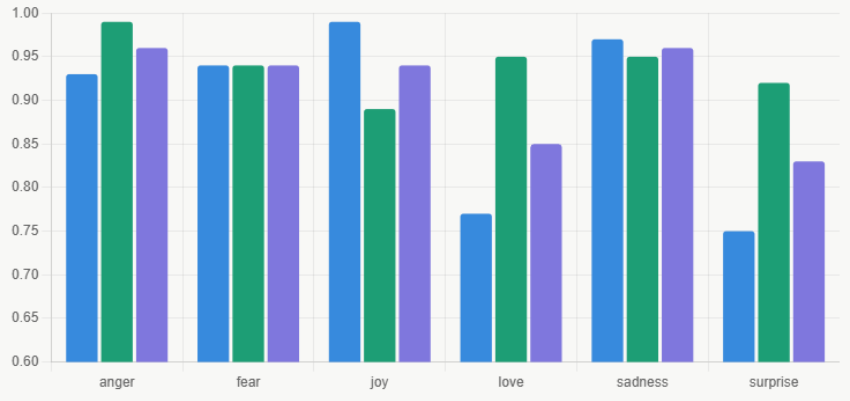


Hình 8. Ma trận nhầm lẫn trên tập Test của mô hình XLM-RoBERTa

Quan sát ma trận nhầm lẫn trong Hình 8 cho thấy phần lớn các mẫu được phân loại đúng nhãn, thể hiện qua các giá trị cao tập trung trên đường chéo chính — cụ thể, anger đạt 98.7%, sadness đạt 95.3%, love đạt 94.9%, fear đạt 94.3% và surprise đạt 92.3%. Điều này cho thấy mô hình XLM-RoBERTa có khả năng học được các đặc trưng ngôn ngữ đặc trưng cho từng lớp cảm xúc một cách hiệu quả.

Các trường hợp nhầm lẫn chủ yếu tập trung ở những cặp cảm xúc có ngữ nghĩa gần nhau. Điển hình nhất là cặp joy và love — cả hai đều mang sắc thái tích cực, dẫn đến sự chồng lấn về đặc trưng ngôn ngữ khiến 6.6% mẫu joy bị phân loại nhầm thành love. Điều này cũng lý giải tại sao precision của love chỉ đạt 77%, thấp nhất trong tất cả các nhãn, do mô hình có xu hướng dự đoán love cho cả những mẫu vốn thuộc lớp khác. Ngoài ra, một tỉ lệ nhỏ mẫu fear (2.9%) bị nhầm sang surprise, phản ánh sự tương đồng về mức độ kích thích cảm xúc giữa hai trạng thái này.

Hình 9 trình bày chi tiết Precision, Recall và F1-score của từng nhãn cảm xúc riêng lẻ, cho phép đánh giá hiệu suất mô hình ở mức độ per-class.



Hình 9. Precision/Recall/F1 theo từng nhãn

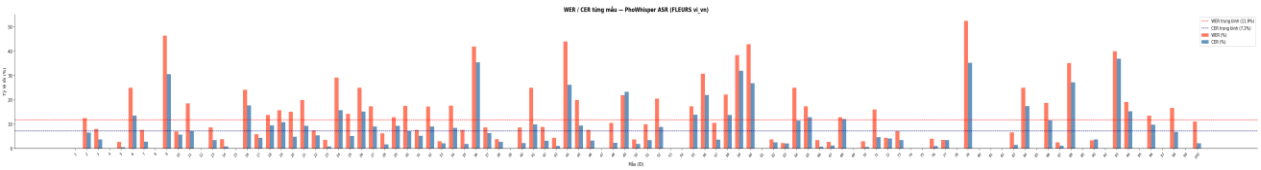
Xét theo từng nhãn, anger và sadness đạt hiệu suất cao nhất với F1-score lần lượt là 96% và 96%, cho thấy mô hình nhận diện tốt các cảm xúc tiêu cực rõ ràng. joy đạt F1 94% với Precision rất cao (99%), tuy nhiên Recall chỉ đạt 89% do một số mẫu joy bị nhầm sang love. Nhãn love có Precision thấp nhất (77%) phản ánh việc mô hình đôi khi dự đoán love cho các câu thực tế thuộc nhãn khác, trong khi Recall 95% cho thấy phần lớn mẫu love thực sự được nhận diện đúng. Surprise có F1 83% với support chỉ 13 mẫu nên chưa thể đánh giá toàn diện — đây là hạn chế của tập kiểm thử hiện tại.

Nhìn chung, mô hình đạt hiệu suất ổn định trên phần lớn các nhãn cảm xúc, với weighted F1 đạt 94% khi tính theo trọng số số lượng mẫu từng nhãn. Kết quả này xác nhận chiến lược fine-tune hai bước (general-domain → domain-specific) cho phép mô hình vừa duy trì năng lực tổng quát vừa thích nghi tốt với đặc thù tiếng Việt hội thoại.

4.3. Đánh giá luồng giọng nói

Luồng giọng nói được đánh giá thông qua hai chỉ số chính là WER (Word Error Rate — tỷ lệ lỗi từ) và CER (Character Error Rate — tỷ lệ lỗi ký tự) trên tập kiểm thử google/fleurs vi_vn với 99 mẫu âm thanh tiếng Việt tự nhiên. Đây là bộ dữ liệu chuẩn được sử dụng rộng rãi trong đánh giá ASR tiếng Việt, bao gồm các câu nói đa dạng về chủ đề và giọng vùng miền.

Mô hình PhoWhisper-small được fine-tune trên tập VietSuperSpeech đạt WER tổng thể 11,85% và CER tổng thể 7,28%, tương ứng với WER trung bình trên từng mẫu là 11,86% và CER trung bình là 7,16%. Hình 10 trình bày tổng hợp kết quả đánh giá và phân bố chất lượng nhận dạng trên toàn bộ tập kiểm thử.



Hình 10. WER/CER tổng hợp và phân bố chất lượng nhận dạng

Trong tổng số 99 mẫu được kiểm tra trong Hình 10, 23 mẫu (23,23%) được nhận dạng hoàn toàn chính xác với WER = 0, phản ánh khả năng xử lý tốt các câu nói ngắn, rõ ràng. Phần lớn các mẫu còn lại có lỗi ở mức nhỏ, chủ yếu do thanh điệu hoặc từ địa phương. WER cực đại ghi nhận được là 52,5% trên các mẫu có nhiễu nền hoặc giọng phát âm không chuẩn, cho thấy mô hình còn hạn chế trong điều kiện môi trường không lý tưởng.

Chênh lệch giữa WER (11,85%) và CER (7,28%) cho thấy các lỗi nhận dạng chủ yếu xảy ra ở cấp độ từ hơn là ký tự đơn lẻ, tức là mô hình nhận dạng được phần lớn các âm tiết cấu thành từ nhưng đôi khi ghép sai thành từ khác do đặc thù hệ thống thanh điệu của tiếng Việt.

Trong bối cảnh ứng dụng của hệ thống, văn bản sau khi nhận dạng từ giọng nói được đưa thẳng vào XLM-RoBERTa để phân tích cảm xúc. Do đó, chất lượng ASR ảnh hưởng trực tiếp đến độ chính xác của nhánh ngữ nghĩa khi người dùng chọn phương thức nhập bằng giọng nói. Với WER 11,85%, phần lớn nội dung ngữ nghĩa được bảo toàn đủ để mô hình cảm xúc dự đoán đúng nhãn, đặc biệt với các câu biểu cảm rõ ràng.

4.4. Đánh giá hệ thống đa phương thức

4.4.1. Đánh giá Fusion Gain trên video có khuôn mặt và tiêm thêm luồng văn bản

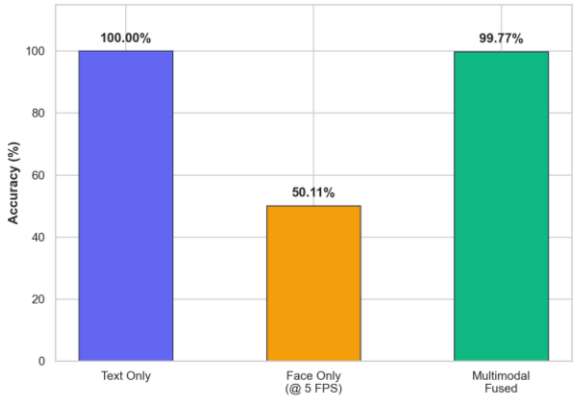
Để đánh giá một cách toàn diện và khách quan năng lực tổng quát hóa của hệ thống Mental Health Monitor, nhóm nghiên cứu không sử dụng lại các tập dữ liệu huấn luyện cục bộ. Thay vào đó, một tiến trình kiểm thử hệ thống (Integration & Stress Testing) quy mô lớn đã được triển khai độc lập trên bộ dữ liệu chuẩn học thuật quốc tế RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song) [30]. Đây là tập dữ liệu chứa cảm xúc của các diễn viên qua hai kênh giọng nói Tiếng Anh và biểu cảm trên khuôn mặt.

Đặc trưng tập mẫu kiểm thử: Tiến trình quét qua 10 diễn viên (bao gồm cả nam và nữ) với tổng quy mô gần 1040 tệp tin video clip ngắn. Kịch bản video yêu cầu nhân vật ngồi chính diện cố định trước camera, mô phỏng hoàn hảo phân phối hình học của người dùng thực tế qua Webcam máy tính. Phương pháp Mô phỏng luồng (Data Mocking & Injection): Do mô hình nhận dạng giọng nói PhoWhisper vận hành chuyên biệt trên không gian ngôn ngữ tiếng Việt, nhóm áp dụng phương pháp lồng ghép dữ liệu kiểm soát: Trích xuất chuỗi thời gian thị giác (Temporal Face Analysis) với tần suất quét 1 FPS từ video gốc, đồng thời chủ động lập trình hệ thống "Inject" (bơm trực tiếp) các chuỗi văn bản ngữ nghĩa tiếng Việt đồng bộ tương ứng với nhãn cảm xúc đích của tệp tin. Mục tiêu cốt lõi của thực nghiệm này là thực hiện phương pháp Ablation Study (Nghiên cứu lược bỏ thành phần) để đo lường chỉ số tăng trưởng hiệu năng Fusion Gain, được định nghĩa theo phương trình (6).

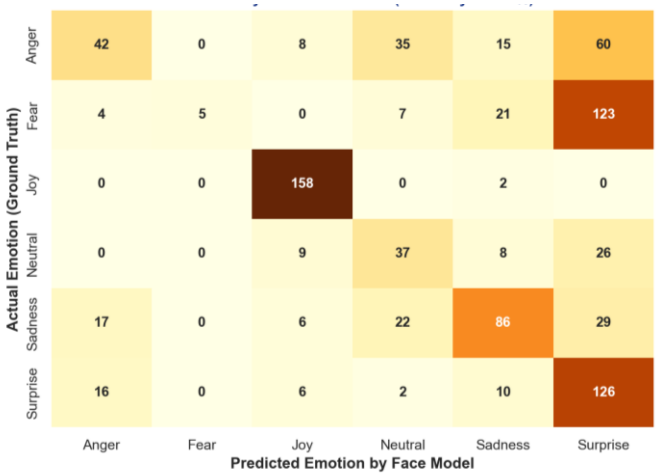
$$Fusion\ Gain = Accuracy_{multimodal} - \max(Accuracy_{Text}, Accuracy_{Face}) \quad (6)$$

Kết quả đối chiếu hiệu năng tổng thể được kiểm thử tự động qua ~1040 mẫu thử nghiệm, kết quả độ chính xác tổng thể (Accuracy) thu được giữa cấu hình đơn phương thức và đa phương thức được tổng hợp tại Hình 11. Độ chính xác của ResNet-18 trên 1040 clip là 51.11

%, chênh lệch khoảng 32% so với tập Test của RAF-DB. Còn kênh văn bản nhận diện chính xác 100% câu từ Tiếng Việt, thể hiện ưu điểm mạnh mẽ của mô hình XLM-Roberta.



Hình 11. Độ chính xác tổng thể qua 1040 mẫu thử nghiệm RAVDESS



Hình 12. Ma trận nhầm lẫn của kênh thị giác trên RAVDESS

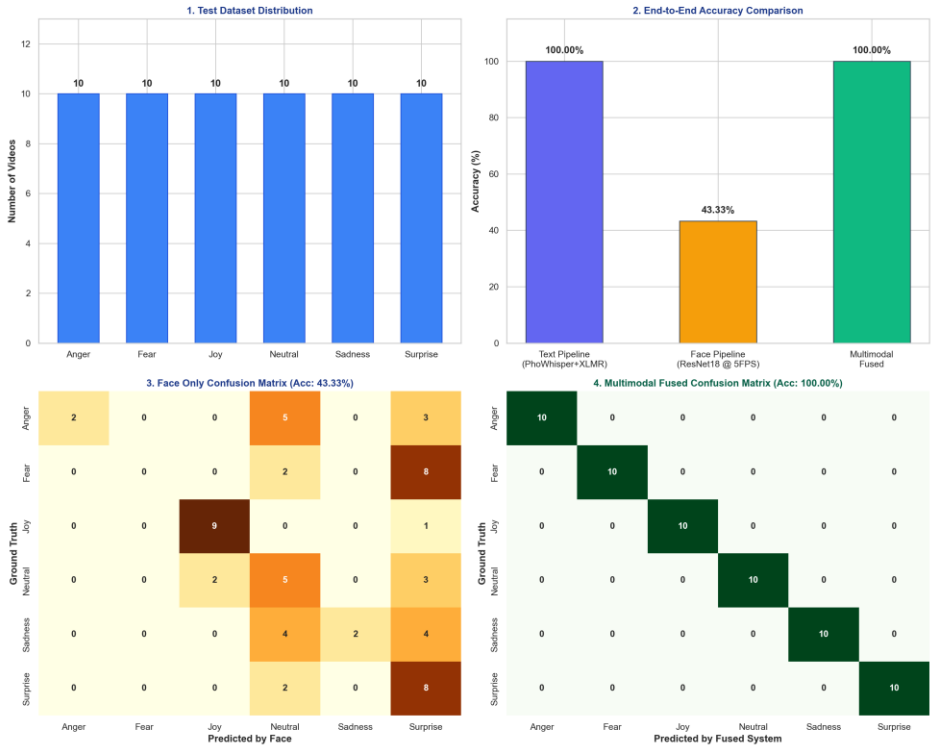
Hình 12 thể hiện ma trận nhầm lẫn của kênh thị giác, nhóm cô lập được điểm mù kinh điển của mạng CNN: Nhiễu khẩu hình phát âm. Hành vi mở rộng cơ miệng liên tục của nhân vật trong quá trình nói đã tạo ra các đặc trưng khuôn mặt tương tự với biểu cảm Ngạc nhiên, khiến mô hình đánh giá sai lệch hàng loạt các lớp cảm xúc tiêu cực như Fear và Anger.

Tuy nhiên, tầng dung hợp đa phương thức Late Fusion đã chứng minh năng lực phòng vệ bộ lọc xuất sắc. Bằng cơ chế phân bổ trọng số thích ứng động theo độ tin cậy thực tế, hệ thống đã vô hiệu hóa thành công các vùng nhiễu của kênh camera, đưa độ chính xác tổng thể toàn hệ thống đạt mức tối ưu (99.77/100.00 %).

4.3.2. Đánh giá Fusion Gain trên Video và Audio

Nhằm đánh giá thêm khả năng phát hiện ngôn từ của PhoWhisper, nhóm đã tiến hành chuẩn bị tập dữ liệu từ RAVDESS, nhóm chọn lọc 6 video thể hiện cảm xúc từ mỗi diễn viên tương ứng với 6 nhãn cảm xúc chung, sau đó lồng thêm tệp âm thanh ngôn từ biểu lộ

cảm xúc tương ứng với nhãn đó, giọng đọc được thực hiện bởi Google. Mục đích là kiểm thử khả năng phát hiện ngôn từ của PhoWhisper và XML-Roberta, đồng thời đánh giá lại khả năng nhận dạng cảm xúc của ResNet-18. Sau quá trình chuẩn bị dữ liệu, 60 video đã được lồng thêm âm thanh đã sẵn sàng đem đi kiểm thử. Kết quả được thể hiện trong Hình 13. Về tổng quan, luồng giọng nói và văn bản đã hoàn thành xuất sắc với 100% độ chính xác. Tuy nhiên, luồng thị giác chỉ đạt 43.33% về độ chính xác tổng thể trên dữ liệu. Quan sát ma trận nhầm lẫn, chỉ có 2 nhãn được nhận dạng tốt nhất là Joy và Surprise. Các nhãn còn lại đa số bị nhầm qua Surprise, một lý do biện luận là nhiễu do khẩu hình miệng, khi diễn viên nói làm cơ miệng biến đổi liên tục khiến cho việc nhận dạng cảm xúc trở nên khó khăn. Việc tích hợp đa phương thức và cơ chế Fusion Late đã góp phần cải thiện đồ án, khi một kênh thông tin bị nhiễu, hệ thống sẽ trao toàn quyền quyết định cho mô hình đang nhận dạng tốt hơn.



Hình 13. Kết quả kiểm tra trên 60 clip RAVDESS được lồng thêm Tiếng Việt

5. Kết luận và hướng phát triển

5.1. Kết luận

Sau quá trình nghiên cứu, thiết kế và thực nghiệm hệ thống, đồ án đã hoàn thành toàn bộ các mục tiêu đặt ra ban đầu, đạt được các kết quả cụ thể sau. Xây dựng thành công kiến trúc Đa phương thức hoàn chỉnh: Nhóm đã thiết kế cấu trúc hệ thống dung hợp thông minh dựa trên 3 luồng thông tin độc lập: Thị giác (Nhận diện biểu cảm khuôn mặt qua mạng

ResNet-18), Ngôn ngữ (Phân tích ngữ nghĩa văn bản qua mô hình XLM-RoBERTa) và Giọng nói (Chuyển đổi tiếng nói sang văn bản thời gian thực bằng bộ dịch PhoWhisper).

Nhóm đồng thời giải quyết được bài toán mất cân bằng dữ liệu nghiêm trọng bằng cơ chế lấy mẫu thông minh, giảm thiểu tác động của việc mất cân bằng lớp, từ đó nâng cao khả năng tổng quát hóa khi áp dụng trên các tập dữ liệu khác và kiểm thử thực tế. Ngoài ra, thuật toán dung hợp muộn Late Fusion dựa trên trọng số động của độ tin cậy, đã chứng minh được tính ưu việt trong các phiên kiểm tra thực nghiệm trên dữ liệu RAVDESS. Hệ thống có khả năng tự động điều chỉnh quyền lực quyết định giữa kênh hình ảnh và kênh ngôn ngữ, giúp phân giải xung đột thông tin hiệu quả và duy trì sự ổn định tối đa trước các biến động nhiễu đầu vào.

5.2. Hạn chế

Mặc dù đạt được những chỉ số thực nghiệm rất khả quan trên tập kiểm thử, hệ thống vẫn tồn tại một số hạn chế nhất định cần được nhìn nhận một cách khách quan: Khuyết điểm ở luồng thị giác, mặc dù đạt được điểm số ổn trên tập dữ liệu RAF-DB, ResNet-18 vẫn gặp khó khăn với khung hình động, nhạy cảm với yếu tố như nhiễu khẩu hình miệng. Điều này làm giảm độ chính xác tổng thể khi kiểm tra hiệu năng của hệ thống trên tập dữ liệu RAVDESS.

Thách thức xử lý ngôn ngữ tự nhiên phi chuẩn: Kênh ngôn ngữ hoạt động tối ưu với cấu trúc câu rõ ràng. Tuy nhiên, khi đối mặt với hội thoại thực tế chứa nhiều từ lóng (Slang), ngôn ngữ mạng, từ địa phương hoặc trường hợp giọng đọc bị chồng lấn âm thanh, bộ dịch PhoWhisper có thể gặp sai số trích xuất văn bản (Word Error Rate), gây ra hiệu ứng lỗi lan truyền (Cascading error) đến mô hình phân loại văn bản XLM-RoBERTa

5.3. Hướng phát triển tương lai

Để khắc phục các hạn chế nêu trên và nâng cao tính thực tiễn của sản phẩm nghiên cứu, hướng phát triển tiếp theo của đồ án sẽ tập trung vào các nhiệm vụ trọng tâm sau: Nâng cấp kiến trúc chuỗi thời gian cho Thị giác: Thay thế bộ phân loại khung hình stateless bằng các mô hình học sâu có khả năng xử lý chuỗi động như Gated Recurrent Units (GRU) hoặc Video Vision Transformers (ViViT) để mô hình hóa chính xác các biến đổi vi biểu cảm (Micro-expressions) theo chiều thời gian. Tích hợp kênh Nhận dạng cảm xúc qua âm thanh trực tiếp (SER): Thay vì chỉ sử dụng giọng nói làm nhiệm vụ chuyển đổi văn bản (ASR), hệ thống sẽ được nâng cấp để trích xuất trực tiếp các đặc trưng âm học cơ bản (như tần số Pitch, cường độ, Mel-spectrogram) qua các cấu trúc mạng Wav2Vec2 hoặc CNN-LSTM, nhằm khai thác triệt để sắc thái tình cảm trong giọng điệu con người.

TÀI LIỆU THAM KHẢO

[1] S. Li and W. Deng, "Deep Facial Expression Recognition: A Survey," *IEEE Transactions on Affective Computing*, vol. 13, no. 3, pp. 1195-1215, 2022.

[2] S. Mirsamadi, E. Barsoum, and C. Zhang, "Automatic speech emotion recognition using recurrent neural networks with local attention," in 2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2017, pp. 2227-2231.

[3] lakshmi25npathi, "IMDB Dataset of 50K Movie Reviews," Kaggle, 2019. [Online]. Available:https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews.

[4] K. Sailunaz and R. Alhajj, "Emotion and sentiment analysis from Twitter text," *Journal of Computational Science*, vol. 36, p. 101003, 2019.

[5] A. Kleinsmith and N. Bianchi-Berthouze, "Affective Body Expression Perception and Recognition: A Survey," *IEEE Transactions on Affective Computing*, vol. 4, no. 1, pp. 15-33, 2013.

[6] W. L. Zheng and B. L. Lu, "Investigating Critical Frequency Bands and Channels for EEG-Based Emotion Recognition with Deep Neural Networks," IEEE Transactions on Autonomous Mental Development, vol. 7, no. 3, pp. 162-175, 2015.

[7] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2014. [Online]. Available: https://arxiv.org/pdf/1409.1556

[8] C. Szegedy et al., “Going deeper with convolutions,” *arXiv preprint arXiv:1409.4842*, 2014. [Online]. Available: https://arxiv.org/pdf/1409.4842

[9] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” *arXiv preprint arXiv:1608.06993*, 2016. [Online]. Available: https://arxiv.org/pdf/1608.06993

[10] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” *arXiv preprint arXiv:1512.03385*, 2015. [Online]. Available:

https://arxiv.org/pdf/1512.03385

[11]“ResNet18_QuantizedWeights,” *PyTorch Documentation*. [Online]. Available:

https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.quantization.resnet18.html#torchvision.models.quantization.ResNet18_QuantizedWeights

[12] I. J. Goodfellow *et al.*, "Challenges in representation learning: A report on three machine learning contests," in *International Conference on Neural Information Processing*,

Springer, Berlin, Heidelberg, 2013, pp. 117–124. [Online]. Available: https://arxiv.org/abs/1307.0414

[13] I. J. Goodfellow et al., "Challenges in representation learning: A report on three machine learning contests," in International Conference on Neural Information Processing, Springer, Berlin, Heidelberg, 2013, pp. 117–124. [Online]. Available: https://arxiv.org/abs/1307.0414

[14] Z. Zhang, P. Luo, C. C. Loy, and X. Tang, "From facial expression recognition to interpersonal relation prediction," *Int. J. Comput. Vis.*, vol. 126, no. 5, pp. 550–569, May 2018, doi: 10.1007/s11263-017-1046-4.

[15] Dev-ShuvoAlok, “RAF-DB Dataset,” *Kaggle Datasets*, 2023. [Online]. Available: https://www.kaggle.com/datasets/shuvoalok/raf-db-dataset. [Accessed: 14-Jan-2026].

[16] M. M. Imran, "Emotion Classification in Software Engineering Texts: A Comparative Analysis of Pre-trained Transformers Language Models," in *Proc. 3rd ACM/IEEE Int. Workshop NL-based Softw. Eng. (NLBSE)*, Lisbon, Portugal, Apr. 2024, pp. 73–80. doi: 10.1145/3643787.3648034. Available: Semantic Scholar

[17] M. Rezapour, "Emotion Detection with Transformers: A Comparative Study," *arXiv preprint*, arXiv:2403.15454, Mar. 2024. [Online]. Available: https://arxiv.org/abs/2403.15454 arXiv

[18] L. Huang, "Deep Learning for Text Sentiment Analysis: A Survey," *Appl. Comput. Eng.*, vol. 104, no. 1, pp. 134–138, Nov. 2024. doi: 10.54254/2755-2721/104/20241153. Available: ResearchGate

[19] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised Cross-lingual Representation Learning at Scale," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Online, Jul. 2020, pp. 8440–8451. doi: 10.18653/v1/2020.acl-main.747. Available: ACL Anthology

[20] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, and C. Raffel, "mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer," in *Proc. 2021 Conf. North Amer. Chapter Assoc. Comput. Linguistics: Human Language Technol. (NAACL-HLT)*, Online, Jun. 2021, pp. 483–498. doi: 10.18653/v1/2021.naacl-main.41. Available: ACL Anthology

[21] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," *J. Mach. Learn. Res.*, vol. 21, no. 140, pp. 1–67, 2020. [Online]. Available: https://arxiv.org/abs/1910.10683

[22] A. Ghandeharioun, D. McDuff, M. Czerwinski, and K. Rowan, "EMMA: An Emotion-Aware Wellbeing Chatbot," in *Proc. 8th Int. Conf. Affective Comput. Intell. Interact. (ACII)*, Cambridge, UK, Sep. 2019, pp. 1–7. doi: 10.1109/ACII.2019.8925455. Available: mit

[23] A. J. Trappey, A. P. Lin, K. Y. Hsu, C. V. Trappey, and K. L. Tu, "Development of an Empathy-Centric Counseling Chatbot System Capable of Sentimental Dialogue Analysis," *Processes*, vol. 10, no. 5, p. 930, May 2022. doi: 10.3390/pr10050930. Available: Springer

[24] M. Schlicher, Y. Li, S. M. K. Murthy, Q. Sun, and B. W. Schuller, "Emotionally Adaptive Support: A Narrative Review of Affective Computing for Mental Health," *Front. Digit. Health*, vol. 7, Art. no. 1657031, Oct. 2025. doi: 10.3389/fdgth.2025.1657031. Available: frontiersin

[25] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust Speech Recognition via Large-Scale Weak Supervision," in *Proc. 40th Int. Conf. Mach. Learn. (ICML)*, Honolulu, HI, USA, Jul. 2023, pp. 28492–28518. [Online]. Available: https://arxiv.org/abs/2212.04356

[26] T.-T. Le, L. T. Nguyen, and D. Q. Nguyen, "PhoWhisper: Automatic Speech Recognition for Vietnamese," in *Proc. ICLR 2024 Tiny Papers Track*, Vienna, Austria, May 2024. [Online]. Available: https://arxiv.org/abs/2406.02555

[27] L. Do, T. N. Nguyen, T. Pham, V. Do, H. Nguyen, and C. Nguyen, "VietSuperSpeech: A Large-Scale Vietnamese Conversational Speech Dataset for ASR Fine-Tuning in Chatbot, Customer Support, and Call Center Applications," *arXiv preprint*, arXiv:2603.01894, Feb. 2026. [Online]. Available: https://arxiv.org/abs/2603.01894

[28] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, Dec. 2020, pp. 12449–12460. [Online]. Available: https://arxiv.org/abs/2006.11477

[29] Y. Wang, Y. Gu, Y. Yin, Y. Han, H. Zhang, S. Wang, C. Li, and D. Quan, "Multimodal Transformer Augmented Fusion for Speech Emotion Recognition," *Front. Neurorobot.*, vol. 17, May 2023, Art. no. 1181598. doi: 10.3389/fnbot.2023.1181598. [Online]. Available: https://doi.org/10.3389/fnbot.2023.1181598

[30] S. R. Livingstone and F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English,” *PLoS ONE*, vol. 13, no. 5, p. e0196391, May 2018, doi: 10.1371/journal.pone.0196391.

Link Github: Backtodagame/PBL4_Final_Project

Link Drive (chứa model chạy code Github): https://drive.google.com/drive/folders/1g-3AZ2uB1vTHn3J-Yr0DB_lm1UTrvGhr?usp=sharing

Link Datasets:

+Nhận dạng cảm xúc khuôn mặt:RAF-DB:

https://www.kaggle.com/datasets/shuvoalok/raf-db-dataset

+Model ResNet-18 RAF-DB:

Tăng cường mạnh: ResNet-18 with RAF-DB

Tăng cường tiêu chuẩn: https://www.kaggle.com/code/trisleevawnminh/resnet-rafdb

+Model speech: **thanhnew2001/VietSuperSpeech · Datasets at Hugging Face**

+Model text: dair-ai/emotion · Datasets at Hugging Face